ECAM-EPMI · 2AE

Module S7MOI1 · Science des Données – Concepts Avancés

Projet final

De la donnée à la décision

Prédire le risque de défaut de paiement d'un prêt personnel

Rapport de synthèse

Réalisé par : **Abdessamad EL IDRISSI**

Intervenant : Yann Skonieczny

Octobre 2026

Résumé en 3 phrases. Nous proposons de remplacer la règle actuelle (refuser les notes internes D à G) par un score de risque qui aide à accorder ou refuser chaque demande de prêt. Sur 6 482 demandes jamais vues, le modèle repère **83 % des défauts** (1 182 sur 1 418) en refusant 24 % des demandes, et 76 % des refus sont justifiés, alors que la règle actuelle ne repère que 42 % des défauts. Sous nos hypothèses, le coût annuel des erreurs passe de 28,2 M$ à 8,4 M$; nous recommandons un **pilote de 3 mois en parallèle de la règle actuelle** pour mesurer le gain réel avant tout déploiement.

Déclaration d'usage de l'IA générative. Un assistant d'IA générative (Claude, Anthropic) a été utilisé pour structurer le dépôt, écrire le code (script et notebooks), rédiger une première version de ce rapport et les slides. Les membres de l'équipe relisent, exécutent et savent expliquer chaque ligne de code et chaque chiffre (cf. annexe C). Tous les chiffres de ce document sont produits par *run_analysis.py* (fichier *reports/results.json*).

Axe 1 · Cadrage de la problématique métier

Élément	Réponse
Contexte	Banque de détail qui propose des prêts personnels (études, santé, travaux, consolidation de dettes…). Utilisateurs du résultat : l'analyste crédit et le responsable des risques.
Problème	Certains emprunteurs ne remboursent pas leur prêt et la banque perd de l'argent ; à l'inverse, refuser un bon client lui fait perdre la marge sur ce prêt.
Décision à éclairer	Pour chaque nouvelle demande : **accorder ou refuser** (ou envoyer en revue humaine), au moment du dépôt du dossier. Le jeu de données ne précise pas l'horizon exact du défaut : c'est une limite assumée (axe 9).
Situation actuelle	*Hypothèse posée* (le processus réel n'est pas documenté) : règle sur la note interne, avec refus des notes D à G. C'est notre référence métier, en plus de « tout accorder ».
Critère de succès	Détecter au moins 80 % des défauts, avec au plus 1 client sain refusé pour 1 défaut évité (Precision ≥ 50 %), et réduire d'au moins 30 % le coût annuel des erreurs par rapport à la règle actuelle, mesuré sur données jamais vues puis confirmé par un pilote de 3 mois.
Contraintes	Seules les informations connues au dépôt du dossier sont utilisables ; modèle explicable ; décision automatisée encadrée (RGPD art. 22, crédit = usage « à haut risque » du règlement européen sur l'IA) donc **humain dans la boucle** ; taux de refus global raisonnable pour ne pas bloquer l'activité.

Axe 2 · Type de problématique

La **cible** est *loan_status* : 1 si le client a fait défaut, 0 s'il a remboursé. Elle est connue pour tout l'historique, donc le problème est **supervisé**, et elle ne prend que deux valeurs : c'est une **classification binaire**. Les autres types sont écartés : une *régression* n'a pas de sens car la sortie n'est pas bornée entre 0 et 1 (et le montant réellement perdu n'est pas dans les données) ; un *clustering* ignorerait l'étiquette dont nous disposons ; une *prévision* est impossible car le jeu ne contient aucune date ; le *multi-classe* n'a pas de raison d'être (un seul type de défaut). La classe positive est minoritaire (21,9 %) : nous en tenons compte dans le split (stratifié) et dans le choix des métriques (axe 5).

Axe 3 · Analyse et préparation des données

Description

Source : *Credit Risk Dataset* (Kaggle) [lien exact, licence et date de consultation à compléter dans le README]. La copie utilisée est celle du dépôt GitHub JoshLG18/DSE-EMP-Project. Elle contient **32 580 demandes** et 12 colonnes, sans variable temporelle. Montants exprimés en dollars (hypothèse, non précisé par la source).

Variable	Type	Signification (unité)
person_age	numérique	Âge du demandeur (années)
person_income	numérique	Revenu annuel ($)
person_home_ownership	catégorielle	Logement : RENT, MORTGAGE, OWN, OTHER
person_emp_length	numérique	Ancienneté dans l'emploi (années)
loan_intent	catégorielle	Objet du prêt (6 modalités : études, santé, travaux, consolidation, personnel, entreprise)
loan_grade	ordinale	Note interne de risque, A (peu risqué) à G (très risqué)
loan_amnt	numérique	Montant du prêt ($)
loan_int_rate	numérique	Taux d'intérêt du prêt (%)
loan_percent_income	numérique	Montant du prêt / revenu annuel (ratio)

Variable	Type	Signification (unité)
cb_person_default_on_file	binaire	Défaut passé enregistré par un bureau de crédit (Y/N)
cb_person_cred_hist_length	numérique	Ancienneté de l'historique de crédit (années)
loan_status	**cible**	**1 = défaut, 0 = remboursé**

Qualité des données et décisions de traitement

- **Valeurs manquantes** : person_emp_length (895 lignes, 2,7 %) et loan_int_rate (3 116 lignes, 9,6 %). Décision : imputation par la **médiane**, ajustée sur le train uniquement dans le Pipeline, avec un indicateur de valeur manquante. Le taux de défaut est quasi identique avec ou sans taux renseigné (20,7 % contre 22,0 %) : le manque ne semble pas informatif.
- **Doublons** : 165 lignes identiques supprimées avant le split (sinon une même ligne pourrait se retrouver dans le train et dans le test).
- **Valeurs impossibles** : âge jusqu'à 144 ans et ancienneté jusqu'à 123 ans. 6 lignes supprimées (âge > 100 ans ou ancienneté > 60 ans). Les revenus extrêmes (jusqu'à 2 039 784 $) sont plausibles : conservés, avec une transformation logarithmique.
- **Jeu final** : 32 409 demandes. Split **stratifié 80/20** : 25 927 en train, 6 482 en test, taux de défaut 21,9 % / 21,9 % (identique).

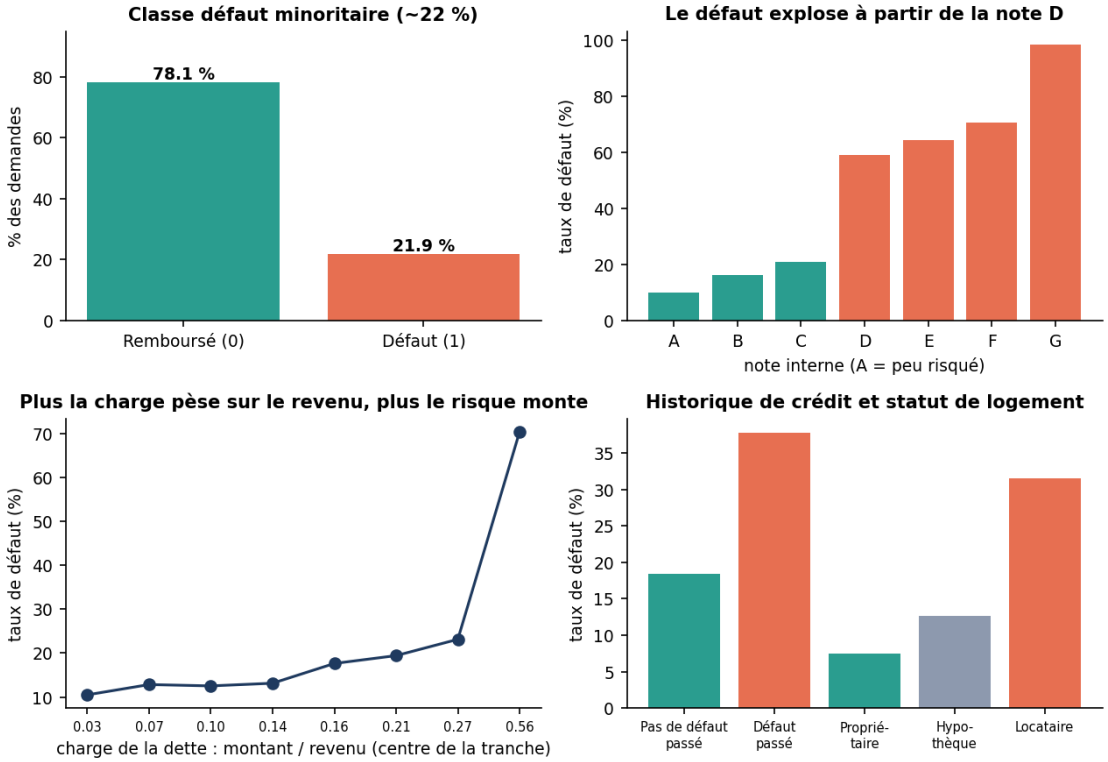


Figure 1 · Le défaut est minoritaire (22 %). Il est très lié à la note interne (de 10 % en A à 98 % en G), à la charge de la dette (montant/revenu) et au statut de logement (locataires ≈ 4 fois plus de défauts que propriétaires). Un défaut passé double le risque.

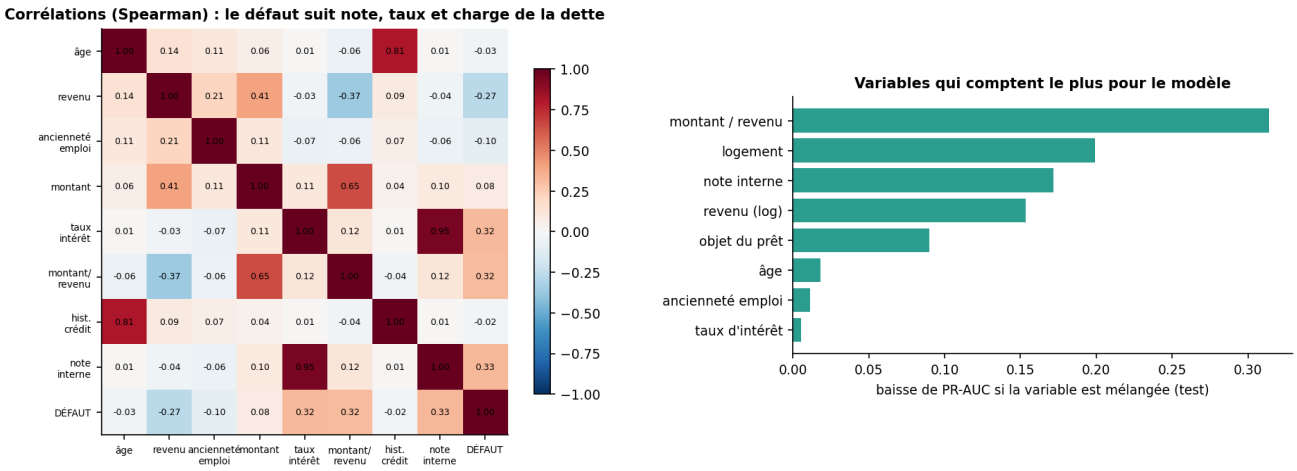


Figure 2 (gauche) · Les variables les plus corrélées au défaut sont le ratio montant/revenu, la note interne et le taux d'intérêt, qui sont eux-mêmes corrélés entre eux (la note détermine le taux). Figure 7 (droite, voir axe 4) · importance par permutation.

Audit de fuite de données

Aucune colonne ne décrit ce qui se passe *après* l'octroi (pas d'historique de remboursement, pas de recouvrement) : **aucune variable n'est exclue pour fuite stricte**. Deux variables restent cependant sous surveillance : *loan_grade* et *loan_int_rate* sont fixées par la banque à l'octroi. Elles sont connues au moment de la décision, mais elles résument déjà une évaluation interne du risque (risque de circularité). Nous les gardons et nous **mesurons leur poids** par ablation à l'axe 4. *loan_percent_income* est le simple ratio montant/revenu : pas de fuite.

Ingénierie de variables (3 variables construites)

- **log_income** = log(1 + revenu) : les revenus sont très asymétriques, le log rend la relation plus lisible pour les modèles linéaires.
- **grade_num** = note A..G codée de 1 à 7 : la note a un ordre naturel de risque.
- **emp_to_age** = ancienneté / âge : mesure la stabilité professionnelle relative (un jeune de 22 ans avec 5 ans d'emploi n'est pas comparable à un homme de 50 ans).

Axe 4 · Développement du modèle

Protocole. Split d'abord, test mis de côté. Toute la préparation (imputation + indicateur, standardisation, one-hot) est dans un *Pipeline / ColumnTransformer* ajusté sur le train uniquement. Six modèles sont comparés en **validation croisée stratifiée à 5 plis** sur le train, avec réglage d'un hyperparamètre au moins (GridSearchCV). Les prédictions sont des probabilités de défaut.

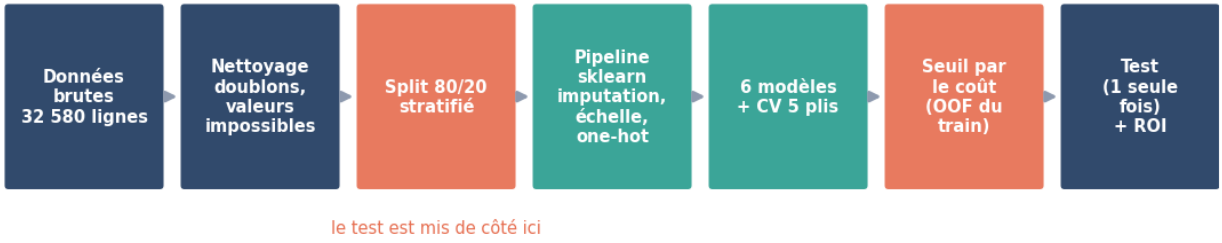


Schéma 1 · Pipeline de bout en bout : le test n'est utilisé qu'une seule fois, à la toute fin.

Modèle	Hyperparam. retenus	PR-AUC train	PR-AUC CV (moy. ± σ)	ROC-AUC CV	Lecture
Baseline (probabilité a priori)	—	0,219	0,219 ± 0,000	0,500	Plancher : aucune discrimination (PR-AUC = taux de défaut)
Régression logistique	C=0.1	0,709	0,708 ± 0,016	0,869	Stable (train ≈ CV) mais limité : relations non linéaires
Arbre sans max_depth	—	1,000	0,616 ± 0,012	0,845	Sur-apprentissage net : train 1,00 contre CV 0,62
Arbre (max_depth réglé)	max_depth=10	0,885	0,863 ± 0,004	0,916	Gros gain obtenu en limitant la profondeur
Random Forest	max_depth=16	0,972	0,879 ± 0,005	0,928	Bon, mais écart train/CV marqué (0,97 contre 0,88)
Gradient Boosting (HGB)	learning_rate=0.1, max_depth=5	0,947	0,899 ± 0,003	0,944	**Meilleur et plus stable (σ = 0,003) : retenu**

Tableau 1 · Comparaison des modèles (PR-AUC = aire sous la courbe Precision-Recall, métrique indépendante du seuil et adaptée à une classe rare). Le score de CV du meilleur réglage est légèrement optimiste, d'où l'intérêt du test final.

Règle de sélection (fixée avant de regarder le test) : meilleur PR-AUC de validation croisée ; en cas d'égalité à un écart-type près, modèle le plus simple. Ici le gradient boosting (HistGradientBoosting) l'emporte nettement (0,899 contre 0,879 pour la Random Forest, écart supérieur à l'écart-type) et bat la baseline de très loin. **Diagnostic** : écart train/validation modéré pour le modèle retenu (0,95 contre 0,90), net pour l'arbre libre (sur-apprentissage) et la forêt.

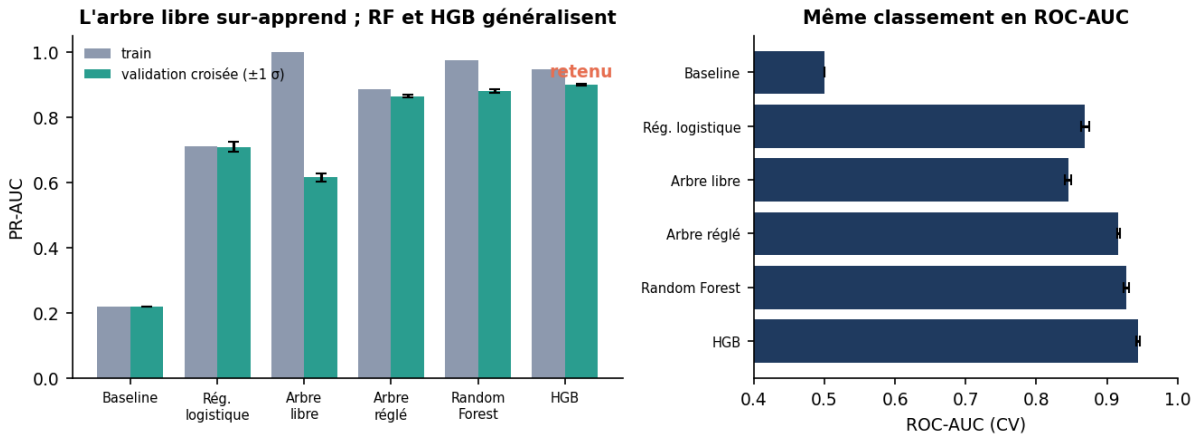


Figure 3 · L'arbre sans limite de profondeur mémorise le train (PR-AUC = 1,00) mais généralise mal ; HGB est le plus performant en validation.

Importance des variables et rôle de la note interne

L'importance par permutation (sur le test, uniquement pour expliquer le modèle final) place en tête le ratio montant/revenu, le statut de logement, la note interne et le revenu. Le taux d'intérêt compte peu : il est largement redondant avec la note. **Ablations** (PR-AUC en CV, train) : modèle complet 0,899 ; **sans l'âge** 0,894 (quasi aucune perte) ; **sans note interne ni taux** 0,808. Sans les deux variables potentiellement circulaires, le modèle reste très au-dessus de la baseline (0,219) : l'essentiel de sa valeur ne vient pas de la note.

Analyse des erreurs

Sur le test, 236 défauts ne sont pas détectés (faux négatifs). Ils ont un profil plus « sain » que les défauts détectés : note moyenne 2,2 contre 3,2 (1 = A, 7 = G), ratio montant/revenu 0,15 contre 0,27, défaut passé dans 17 % des cas contre 35 %. Ces défauts « surprises » sont par nature les plus difficiles à anticiper avec les seules données du dossier.

Axe 5 · Choix des métriques

- **Métrique principale de décision : Recall sur la classe défaut**, car un défaut non détecté coûte beaucoup plus cher qu'un refus à tort (environ 5 fois plus sous nos hypothèses, axe 6).
- **Garde-fou : Precision ≥ 50 %** (au plus 1 client sain refusé pour 1 défaut évité), pour ne pas détruire l'activité commerciale. On suit aussi le **taux de refus global**.
- **Comparaison des modèles : PR-AUC** (indépendante du seuil, adaptée à la classe rare), complétée par la ROC-AUC. **F1** affiché pour information.
- **Accuracy écartée** : accorder tous les prêts donne déjà 78,1 % d'accuracy sans détecter aucun défaut.

Axe 6 · Justification métrique et business

Matrice de coûts (hypothèses explicites, à valider avec la banque). Le seuil décide : on **refuse si le score de risque ≥ seuil**. Faux négatif (prêt accordé puis défaut) : perte = **60 % du montant** (perte en cas de défaut, LGD ; le reste étant récupéré). Faux positif (bon client refusé) : manque à gagner = **12 % du montant** (marge nette sur la durée du prêt). Vrai positif et vrai négatif : pas de coût d'erreur (la marge des prêts sains accordés est identique avec ou sans modèle). Les coûts sont calculés prêt par prêt, proportionnellement au montant. Le seuil théorique qui minimise ce coût est **marge/(marge + LGD) = 0,17** pour un modèle bien calibré, ce qui est très loin du seuil par défaut de 0,5.

Seuil (OOF train)	Precision	Recall	F1	Taux de refus	Coût d'erreur total (train)
0,2 (retenu)	75 %	82 %	0,78	24 %	7,13 M$
0,3	87 %	77 %	0,82	20 %	7,62 M$
0,5	97 %	73 %	0,83	17 %	8,23 M$
Accorder tout	—	0 %	0,00	0 %	36,84 M$

*Tableau 2 · Analyse du seuil sur les prédictions hors-échantillon du **train** (cross_val_predict) : le test n'intervient pas dans le choix du seuil.*

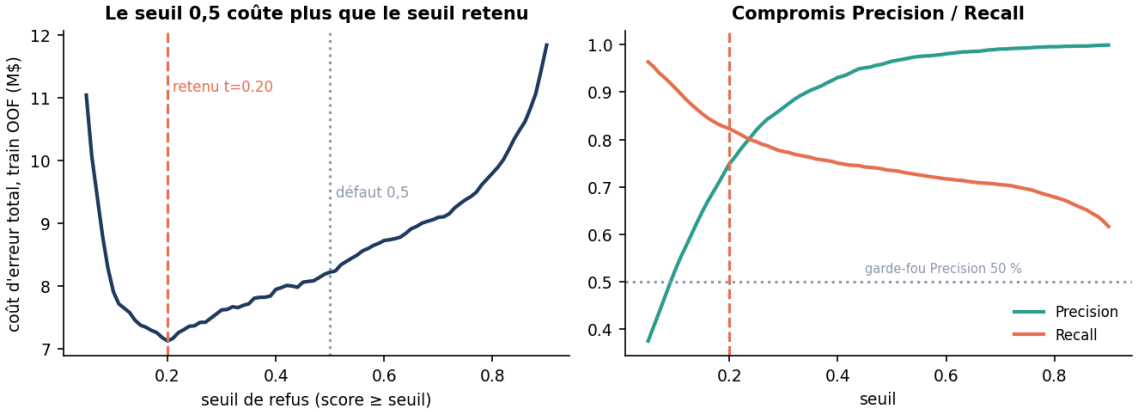


Figure 4 · Le coût d'erreur est minimal autour de 0,20. Le garde-fou Precision ≥ 50 % n'est pas contraignant ici ; le seuil 0,5 a le meilleur F1 mais coûte plus cher.

Conclusion. Le seuil 0,5 maximise le F1, mais le seuil **0,20** réduit le coût d'erreur de 13 % sur le train. Le meilleur modèle statistique n'est pas le meilleur modèle économique. Le seuil de 0,20 est retenu.

Résultat final sur le test (utilisé une seule fois)

Stratégie	TP	FP	FN	Precision	Recall	F1	Refus	Coût d'erreur (test)
Modèle, seuil 0,20	1 182	374	236	76 %	83 %	0,79	24 %	1,70 M$
Modèle, seuil 0,5	1 048	22	370	98 %	74 %	0,84	17 %	2,01 M$
Règle actuelle (notes D-G)	599	393	819	60 %	42 %	0,50	15 %	5,71 M$
Tout accorder	0	0	1 418	0 %	0 %	0,00	0 %	9,32 M$

Tableau 3 · 6 482 demandes de test, 1 418 défauts réels. ROC-AUC test = 0,949 et PR-AUC test = 0,907 (contre 0,899 en CV) : la performance se confirme sur des données jamais vues.

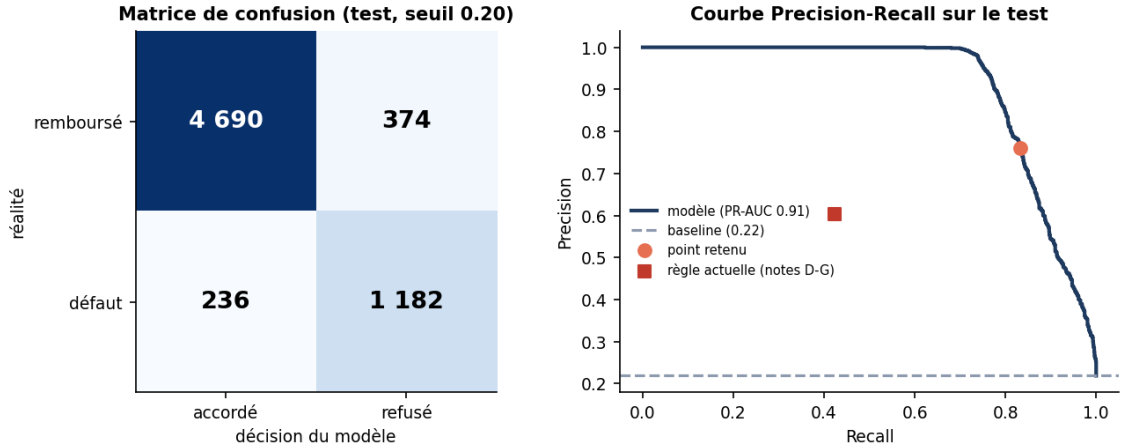


Figure 5 · Matrice de confusion et courbe Precision-Recall sur le test : le modèle domine la règle actuelle.

Traduction métier : « sur 100 défauts, le modèle en anticipe 83, contre 42 pour la règle actuelle ; sur 100 refus, 76 sont justifiés ». Le modèle refuse 24 % des demandes (contre 15 % pour la règle) : il refuse davantage, mais mieux. Le coût d'erreur sur le test est de 1,70 M$, contre 5,71 M$ pour la règle actuelle.

Attention : sur ce jeu, la précision reste proche de 100 % pour les scores les plus élevés (figure 5). Le jeu de données paraît très « propre », peut-être en partie synthétique : ces performances sont probablement plus optimistes que sur un vrai portefeuille.

Axe 7 · ROI potentiel

Méthode. Les résultats du test sont ramenés à une année en supposant **32 000 demandes par an** (hypothèse de volume, facteur 4,94 sur le test). « Coût sans modèle » = coût d'erreur de la règle actuelle. Gain annuel mesuré = coût sans modèle − coût avec modèle. Comme le gain mesuré hors échantillon est probablement trop beau, nous le **décotons** d'une part « réalisée en production » (adoption partielle, dérive, biais de sélection). Coût du projet 1re année (central) = 150 k$: développement 80 k$ + intégration et validation 30 k$ + exploitation 40 k$. ROI (%) = (gain annuel − coût du projet) / coût du projet × 100 ; délai de retour = coût du projet / (gain annuel / 12).

Scénario	LGD	Marge	Coût projet	Gain réalisé	Coût sans modèle	Coût avec modèle	Gain annuel	ROI an 1	Retour
Pessimiste	40 %	15 %	250 k$	40 %	20,4 M$	6,8 M$	5,4 M$	2 071 %	0,6 mois
Central	60 %	12 %	150 k$	70 %	28,2 M$	8,4 M$	13,9 M$	9 147 %	0,1 mois
Optimiste	75 %	10 %	120 k$	100 %	34,1 M$	9,6 M$	24,5 M$	20 327 %	0,1 mois
Dérive (scores bruités)	60 %	12 %	150 k$	70 %	28,2 M$	11,9 M$	11,4 M$	7 524 %	0,2 mois

Tableau 4 · Scénarios de ROI (seuil fixé à 0,20 dans tous les cas). Le scénario « dérive » ajoute du bruit aux scores pour simuler un modèle qui se dégrade.

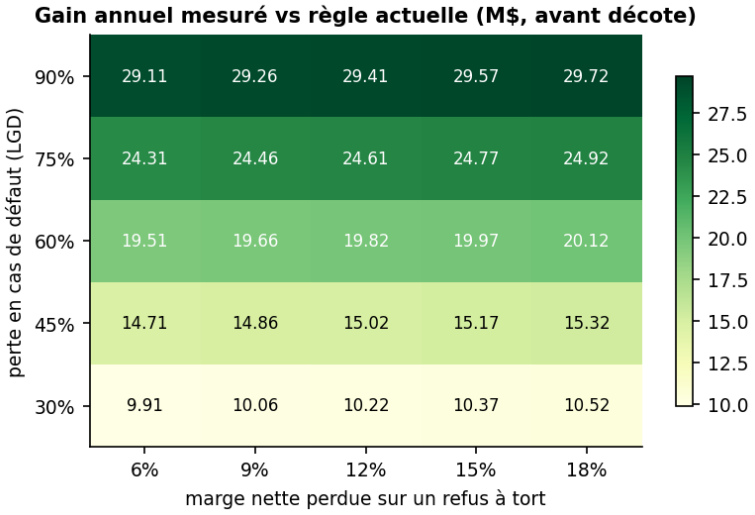


Figure 6 · Sensibilité du gain mesuré (avant décote) aux deux hypothèses de coût : le gain dépend surtout de la perte en cas de défaut (LGD), très peu de la marge.

Lecture et mise en garde. Le projet reste très largement rentable dans les quatre scénarios, et même avec seulement 10 % du gain mesuré (ROI 1 221 %). **Point mort** : il suffirait que 0,8 % du gain mesuré se réalise pour rembourser le projet en un an. Ces ROI sont énormes parce que les pertes évitées (de l'ordre de 20 M$ par an) sont sans commune mesure avec le coût d'un projet de données : **ils ne doivent pas être lus comme une prévision**. Ordre de grandeur indépendant du volume : environ 619 k$ de gain mesuré pour 1 000 demandes. L'hypothèse la plus critique est le niveau de la LGD et la qualité de la référence (la règle actuelle est supposée, et le modèle utilise la même note interne) : c'est ce que le pilote doit valider en priorité.

Axe 9 · Risques et enjeux

Risque	Catégorie	Proba.	Impact	Mesure de réduction
Biais de sélection : l'historique ne contient que des prêts accordés, pas les clients refusés (« reject inference »)	Technique	Élevée	Élevé	Pilote en parallèle, sans décision automatique ; accorder un petit échantillon aléatoire pour mesurer le défaut des profils à risque.
Circularité de la note interne : le modèle réutilise un jugement existant	Technique	Moyenne	Moyen	Ablation faite (PR-AUC 0,81 sans note ni taux) ; suivre le modèle sans ces variables comme modèle de contrôle.
Dérive des données (conjoncture, nouveaux produits, taux)	Technique	Moyenne	Élevé	Suivi mensuel du Recall, de la Precision et des distributions ; réentraînement trimestriel ; règle de repli (règle actuelle).
Performances surestimées (jeu très propre, possiblement synthétique)	Technique	Moyenne	Élevé	Valider sur les données réelles de la banque avant déploiement ; décote de 30 % dans le ROI central.
Coût réel (LGD, marge) différent des hypothèses	Métier	Moyenne	Élevé	Faire valider LGD et marge par la direction des risques ; pilote de 3 mois.
Adoption : analystes qui ignorent ou suivent aveuglément le score	Métier	Moyenne	Élevé	Score présenté comme aide à la décision avec les 3 variables qui l'expliquent ; revue humaine des cas proches du seuil.
Discrimination indirecte (statut de logement, âge)	Éthique	Moyenne	Élevé	Retirer l'âge (perte négligeable) ; auditer les taux de refus par groupe à chaque réentraînement ; revue juridique.
Décision automatisée et explicabilité (RGPD art. 22, règlement IA)	Régle-mentaire	Élevée	Élevé	Humain dans la boucle, explication des principaux facteurs au client, journalisation des décisions.
Coût énergétique	Environ-nement	Faible	Faible	Entraînement d'environ 1 minute sur CPU : négligeable face au gain attendu.

Tableau 5 · Registre de risques propre à ce projet.

Audit d'équité sur le test (seuil 0,20)

Groupe	Effectif	Taux de défaut réel	Taux de refus	Recall	Faux refus (FPR)
Âge < 25	2 380	22,8 %	24,6 %	85 %	6,7 %
Âge 25-29	2 257	22,4 %	24,6 %	82 %	7,9 %
Âge ≥ 30	1 845	20,1 %	22,5 %	82 %	7,5 %
Locataire	3 275	31,4 %	34,6 %	89 %	9,7 %
Hypothèque	2 651	12,9 %	14,2 %	65 %	6,7 %
Propriétaire	533	7,9 %	7,7 %	95 %	0,2 %

Tableau 6 · Par âge, les taux de refus suivent de près les taux de défaut réels, sans écart marqué. Le statut de logement montre des différences plus fortes : les locataires sont refusés bien plus souvent (35 %) mais ils font aussi bien plus défaut (31 %). Le Recall est plus faible pour les emprunteurs avec hypothèque (65 %) : le modèle y rate plus de défauts. Ces écarts justifient un suivi régulier, sans prouver à eux seuls une discrimination.

Limites et suite : pas de date dans le jeu (pas de validation temporelle), horizon de défaut inconnu, historique limité aux prêts accordés, volumes et coûts supposés. Prochaines étapes : valider les hypothèses de coût avec la banque, calibrer les probabilités, tester un modèle sans l'âge, lancer le pilote de 3 mois.

Annexe A · Dépôt Git et reproductibilité

Structure du dépôt (conforme aux consignes) :

Élément	Rôle
README.md	Problème, résultats clés, ROI, comment lancer, usage de l'IA déclaré
requirements.txt	Versions des librairies (pandas, numpy, scikit-learn, matplotlib, reportlab, pillow)
data/credit_risk_dataset.csv	Données brutes (1,8 Mo, sous la limite de 50 Mo)
src/features.py, src/costs.py	Fonctions réutilisables : nettoyage, variables, coûts, métriques, ROI
notebooks/	01_cadrage_eda, 02_modelisation, 03_decision_roi (exécutés, sans erreur)
run_analysis.py	Exécute tout le pipeline (random_state=42, chemins relatifs) et écrit reports/results.json et les figures
build_report.py	Génère ce rapport PDF à partir de results.json : les chiffres du rapport sont ceux du code
reports/	Rapport PDF, figures, results.json

Pour reproduire : **pip install -r requirements.txt**, puis exécuter dans l'ordre les notebooks *01_cadrage_eda*, *02_modelisation*, *03_decision_roi* (« Restart & Run All », environ 4 minutes au total sur un CPU), ou bien **python run_analysis.py** pour le même résultat en une commande. Les notebooks et le script donnent les mêmes chiffres (random_state=42).

Annexe B · Plan de soutenance (10 minutes, binôme)

Partie	Contenu	Visuel	Temps
1. Le problème	Décision accorder/refuser, règle actuelle, critère de succès	Tableau de cadrage	1 min 30
2. Les données	32 580 demandes, qualité, 3 constats clés, audit de fuite	Figure 1 (EDA)	2 min
3. La démarche	Classification binaire, pipeline sans fuite, 6 modèles en CV	Schéma 1 + Tableau 1	2 min 30
4. Les résultats	Métrique, seuil par le coût, résultat sur le test, erreurs typiques	Figures 4 et 5, Tableau 3	2 min
5. La valeur	ROI en 4 scénarios, décote, recommandation de pilote	Tableau 4	1 min 30
6. Limites et suite	Biais de sélection, équité, dérive, prochaines étapes	Tableau 5	30 s

Chaque membre prend la parole ; prévoir une capture d'écran de secours. Les questions du jury (5 min) porteront sur le code : chacun doit pouvoir expliquer le Pipeline, le choix du seuil, la décote du ROI et les limites.

Annexe C · Check-list finale (consignes, section 15)

Point	État
Décision métier et critère de succès écrits en une phrase chacun	Fait (axe 1)
Type de problème justifié, alternatives écartées	Fait (axe 2)
Aucune variable inconnue au moment de la décision	Fait (audit de fuite, axe 3)
Préparation dans un Pipeline ajusté sur le train	Fait (run_analysis.py)
Baseline présente et battue	Fait (Tableau 1)
CV avec écart-type, train vs validation comparés	Fait (Tableau 1)
Test utilisé une seule fois	Fait (Tableau 3)
Métrique et seuil justifiés par les coûts	Fait (axes 5-6)
ROI avec hypothèses et scénario défavorable	Fait (axe 7)
Risques spécifiques avec mesures	Fait (axe 9)
Restart & Run All sur les notebooks	Fait (3 notebooks exécutés sans erreur)
Source des données (lien, licence, date) dans le README	**À compléter**
Oral répété en temps réel ; chacun sait expliquer chaque ligne de code	**À faire par l'équipe**