Prédire le risque de défaut d'un prêt personnel

De la donnée à la décision · Projet final S7MOI1 · ECAM-EPMI · 2AE

Abdessamad EL IDRISSI · Octobre 2026

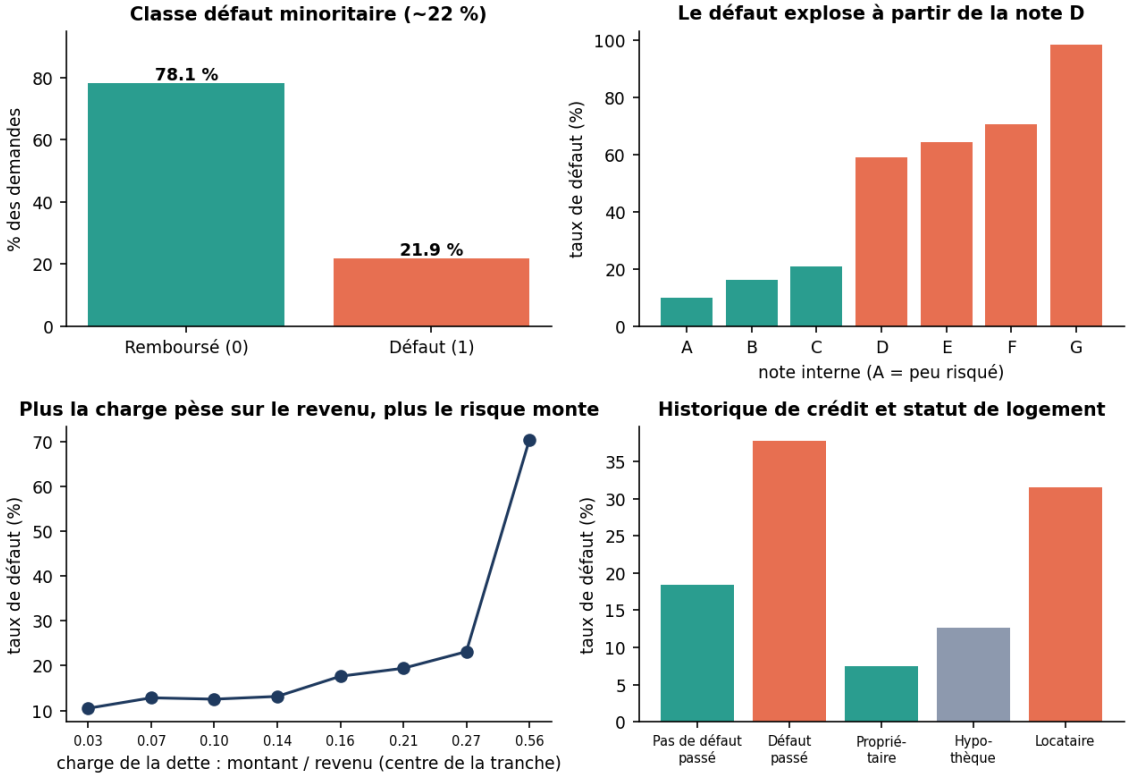
1. Le problème

- Banque de détail : certains emprunteurs ne remboursent pas, refuser à tort un bon client fait aussi perdre de l'argent.
- **Décision** : pour chaque demande, accorder ou refuser (aide à la décision de l'analyste crédit).
- **Situation actuelle (hypothèse)** : refus des notes internes D à G.
- **Critère de succès** : détecter au moins 80 % des défauts, avec au plus 1 refus à tort pour 1 défaut évité, et réduire le coût d'erreur d'au moins 30 %.

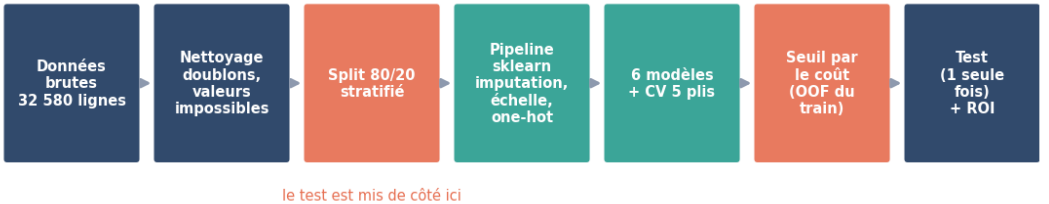
2. Les données

- Credit Risk Dataset : **32 580 demandes**, 11 variables, cible binaire (défaut = 22 %).
- Qualité : valeurs manquantes (ancienneté, taux) imputées dans le pipeline ; 165 doublons et 6 valeurs impossibles (âge 144 ans) supprimés.
- Audit de fuite : aucune variable de l'après-octroi. **Note interne et taux** : connus à la décision mais circulaires, donc testés par ablation.
- Split stratifié 80/20 fait **avant** toute préparation ; le test n'est utilisé qu'une fois.

3. Ce que montrent les données



4. La démarche



- Classification binaire supervisée (régression, clustering et prévision écartés).
- Pipeline scikit-learn : imputation, standardisation, one-hot, tout ajusté sur le train.
- 6 modèles en validation croisée 5 plis, réglage d'hyperparamètres, baseline obligatoire.

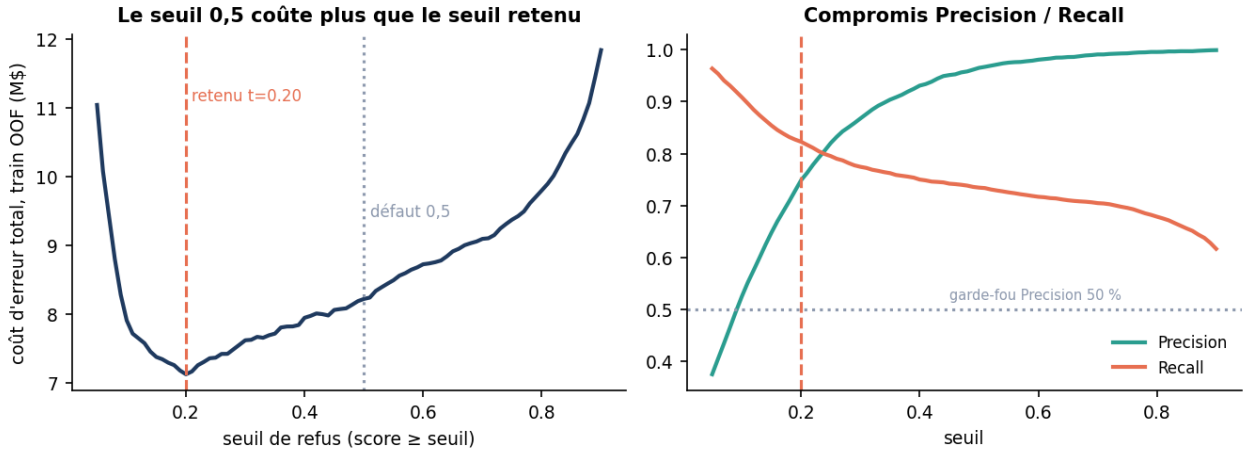
5. Modèles comparés (validation croisée)

Modèle	PR-AUC train	PR-AUC CV (± σ)	Lecture
Baseline (probabilité a priori)	0,22	0,219 ± 0,000	Plancher
Régression logistique	0,71	0,708 ± 0,016	Stable mais limité
Arbre sans max_depth	1,00	0,616 ± 0,012	Sur-apprentissage net
Arbre (max_depth réglé)	0,88	0,863 ± 0,004	Gain avec max_depth
Random Forest	0,97	0,879 ± 0,005	Écart train/CV marqué
Gradient Boosting (HGB)	0,95	0,899 ± 0,003	**Retenu : meilleur et stable**

L'arbre libre mémorise le train (1,00) mais généralise mal. Le gradient boosting bat la baseline et les autres modèles.

6. Métrique et seuil choisis par le coût

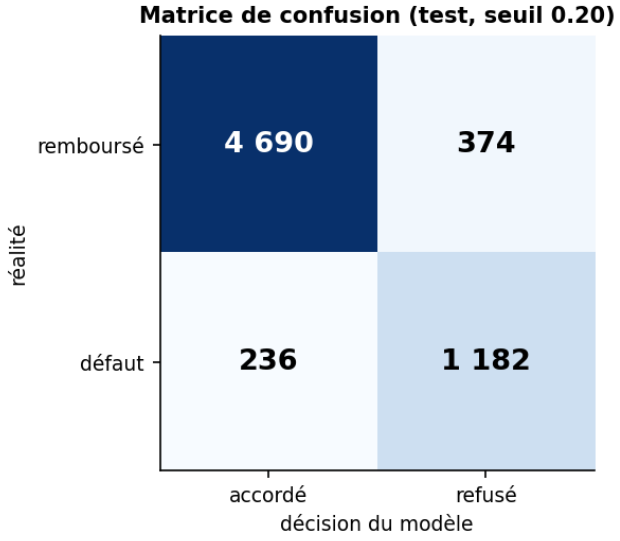
- Métrique principale : **Recall** sur les défauts ; garde-fou Precision ≥ 50 %. Accuracy écartée (tout accorder donne déjà 78 %).
- Coûts (hypothèses) : défaut non détecté = 60 % du montant ; bon client refusé = 12 % du montant.

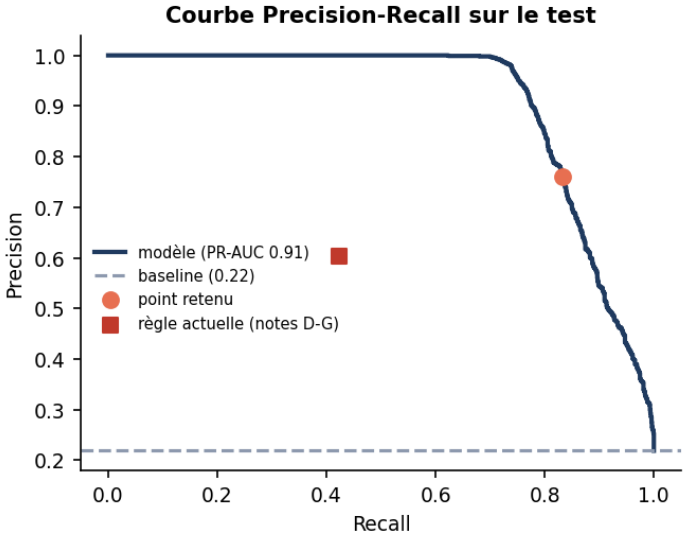


Seuil retenu : 0,20 (et non 0,5), choisi sur le train.

7. Résultats sur des données jamais vues

Stratégie (test)	Recall	Precision	Refus	Coût d'erreur
Modèle, seuil 0,20	83 %	76 %	24 %	1,70 M$
Règle actuelle (notes D-G)	42 %	60 %	15 %	5,71 M$
Tout accorder	0 %	—	0 %	9,32 M$





« Sur 100 défauts, le modèle en anticipe 83, contre 42 pour la règle actuelle. »

8. La valeur : ROI et scénarios

Scénario	Part du gain réalisée	Coût du projet	Gain annuel	ROI an 1
Pessimiste	40 %	250 k$	5,4 M$	2 071 %
Central	70 %	150 k$	13,9 M$	9 147 %
Optimiste	100 %	120 k$	24,5 M$	20 327 %
Dérive (scores bruités)	70 %	150 k$	11,4 M$	7 524 %

- Hypothèses explicites : 32 000 demandes/an, LGD 60 %, marge 12 %, gain mesuré décoté de 30 % dans le central.
- Point mort : il suffit que 0,8 % du gain mesuré se réalise. **Ce ROI n'est pas une prévision** : la LGD et la qualité de la référence sont à valider.

9. Risques et limites

- **Biais de sélection** : l'historique ne contient que des prêts accordés (pilote en parallèle).
- **Circularité** de la note interne ; sans elle PR-AUC 0,81 (reste très au-dessus de la baseline 0,22).
- **Équité et réglementation** : retirer l'âge, auditer les refus par groupe (logement), humain dans la boucle (RGPD art. 22).
- **Dérive** : suivi mensuel du Recall, réentraînement trimestriel. **Jeu très propre**, possiblement synthétique : performances probablement optimistes.

10. Recommandation

- Remplacer la règle seule par un **score de risque en aide à la décision**.
- Lancer un **pilote de 3 mois en parallèle** de la règle actuelle pour mesurer le coût réel (LGD, marge) avant déploiement.
- Valider les hypothèses avec la direction des risques, tester un modèle sans l'âge, calibrer les probabilités.